

¿Gana el no favorito?

Un dataset donde **una fila es un partido**, construido para responder si el equipo no favorito ganará, a partir de las probabilidades implícitas del mercado de apuestas y de los **atributos intrínsecos de los 22 jugadores que efectivamente salieron a la cancha**. Este documento registra cada decisión de diseño y el significado de las 82 columnas.

FILAS	COLUMNAS	CLAVE PRIMARIA	COBERTURA	PERÍODO
19.694 un partido cada una	82 ver diccionario	match_id sin duplicados	9 ligas 8 temporadas, 9 países	2008-2016 09/08/2008 al 17/05/2016

La pregunta y la unidad de análisis

¿Ganará el equipo no favorito un partido, dadas las probabilidades implícitas de las apuestas pre-partido y las métricas intrínsecas de cada uno de los jugadores que salen a la cancha?

La unidad de análisis es el partido, y eso fija todo lo demás. El favorito se define por el mercado; el no favorito es el otro; y el objetivo `gano_no_favorito` responde por sí o por no. Cada fila combina tres bloques: el mercado convertido a probabilidades, los features derivados de los 22 titulares reales, y el resultado observado.

Fuente

European Soccer Database ([hugomathien/soccer](#)), un único archivo SQLite de ~300 MB con 25.979 partidos de 11 ligas europeas. Aporta las tres cosas que el proyecto necesita en un solo lugar: cuotas 1X2 de 10 casas de apuestas, **la alineación titular real de cada partido** con la posición de cada jugador en la cancha, y 183.978 snapshots fechados de atributos individuales de 11.060 jugadores (linaje FIFA/sofifa).

Decisiones de diseño

Cada decisión tiene un identificador estable (D1...D11) para poder citarla. El orden va de la más estructural a la más operativa.

D1

Una fila es un partido, no un jugador

Lo estrictamente *tidy* sería una fila por par (partido, jugador): 433.268 filas. Pero entonces la unidad de análisis dejaría de ser el partido, que es justo lo que la pregunta pide predecir. La concesión deliberada es que **una fila comprime a 22 jugadores** en agregados que apuntan a individuos concretos.

CÓMO QUEDA A LA VISTA

La columna `*_xi_sin_atributos` informa, fila por fila, cuántos de los 11 titulares no tenían snapshot previo de atributos. Vale 0 en el 99,9% de las filas.

D2

Una sola fuente, y no las dos originales

El plan inicial cruzaba [sofifa.com](https://www.sofifa.com) (atributos) con [football-data.co.uk](https://www.football-data.co.uk) (resultados y cuotas). Se descartó por dos razones distintas: sofifa bloquea explícitamente a los bots en su `robots.txt` (`Disallow: /` para ClaudeBot, GPTBot y otros, más `Content-Signal: ai-train=no`) y está detrás de Cloudflare, así que scrapearlo exigiría evadir una protección puesta a propósito; y [football-data.co.uk](https://www.football-data.co.uk) venía devolviendo `HTTP 503` durante días.

La base de Kaggle resuelve las dos cosas en un archivo y agrega lo que ninguna de las dos tenía: las alineaciones titulares. Además trae `player_api_id` y `team_api_id`, así que **el join es por id y no por nombre**: desaparece la fragilidad de mapear "Man United" contra "Manchester United".

D3

Nada de promedios de plantel


Ninguna columna promedia a los 30+ jugadores del club. Todas salen de los 11 que salieron a la cancha ese día, y cada una se puede rastrear a jugadores concretos: el arquero titular (`gk_overall`, `gk_reflexes`), el mejor jugador en cancha (`best_overall`), los tres mejores individuos (`top3_overall`), el eslabón más débil (`worst_overall`), el más rápido (`fastest_sprint_speed`), el mejor definidor (`best_finishing`).

`overall_std` merece mención aparte: mide la dispersión del once, o sea si el equipo es estrella-dependiente o parejo. Un promedio no distingue esas dos cosas.

D4

Sin fuga de información temporal

Los atributos de jugador vienen fechados, así que usar el rating "actual" filtraría información del futuro. El cruce se hace con `merge_asof(direction="backward", allow_exact_matches=False)`: para cada jugador se toma su snapshot más reciente **estrictamente anterior** a la fecha del partido.



`allow_exact_matches=False` es lo que descarta el snapshot fechado el mismo día del partido: podría haberse publicado después del pitazo inicial. Nunca entra un rating posterior al encuentro.

D5

Probabilidades normalizadas, no cuotas crudas

Una cuota no es una probabilidad: incluye el margen de la casa. El pipeline invierte las tres cuotas ($1/\text{cuota}$), suma el resultado para obtener el **overround** y divide por él, de modo que $\text{prob_home} + \text{prob_draw} + \text{prob_away} = 1.0$ exactamente.

VERIFICADO

Las tres probabilidades suman 1.0 en las 19.694 filas, sin una sola excepción. El overround medio es 1,0427, o sea que las casas se quedan con un 4,3% en promedio. Queda como columna porque es la evidencia que justifica la elección de casa (D6).

D6

Una casa de apuestas por fila, y registrada

Promediar cuotas de varias casas mezclaría mercados con márgenes distintos. Se usa una sola por fila, con orden de preferencia **Pinnacle** → **Bet365** → **el resto**, y la columna `odds_source` deja constancia de cuál se usó. Pinnacle es la referencia en los estudios de eficiencia de mercado precisamente porque tiene el margen más bajo, y el dato lo confirma: overround medio 1,024 contra 1,065 de Bet365.

CASA	FILAS	COBERTURA	OVERROUND MEDIO
PS	10.446	53,0%	1,0237
B365	9.245	46,9%	1,0648
BW	2	0,01%	1,0788
BS	1	0,01%	1,1145

Pinnacle no cubre las temporadas anteriores a 2012/2013, de ahí que Bet365 aporte casi la mitad de las filas. Las 3 filas de BW y BS son partidos donde ninguna de las dos casas principales tenía la tripleta completa.

D7

El empate cuenta como `False`

La pregunta es "¿ganará el no favorito?". Si empató, no ganó: el target vale `False`. Dejarlo nulo tiraría el 25,2% de las filas, y tratarlo como una tercera clase cambiaría la pregunta.


LA INFORMACIÓN NO SE PIERDE

`resultado_no_favorito` conserva el detalle en tres niveles — `gano` (21,4%), `empato` (25,2%), `perdio` (53,4%) — así que quien quiera modelar las tres clases tiene la columna disponible.

D8

La línea de cada titular sale de su coordenada en la cancha

La base trae, para cada titular, una coordenada `Y` con su ubicación en el campo. Usarla en lugar de la posición nominal del jugador hace que las columnas por línea respeten **la formación que efectivamente salió a jugar** ese partido, y no el puesto teórico del jugador en su ficha.



Los valores de `Y` presentes en la base y el bin donde cae cada uno. El corte en 7 es la fuente de la limitación L1: hay que leer `formacion` como "cuántos titulares por tercio de cancha", no como la etiqueta táctica del entrenador.

D9

Features orientados a la pregunta, no sólo a la cancha

Las columnas `*_gap` miden local menos visitante, que es una diferencia neutral. Las `nofav_*_gap` miden el **no favorito menos el favorito**: un valor positivo significa que el underdog es superior en esa dimensión. Es la forma directa de responder la pregunta, en vez de dejarle al modelo el trabajo de combinar `equipo_favorito` con un gap orientado a la localía.

LOS FEATURES APORTAN SEÑAL POR ENCIMA DEL MERCADO

Cuando el once del no favorito es mejor en papel (`nofav_xi_overall_mean_gap > 0` , 4.526 partidos), su tasa de triunfo sube de 19,3% a 28,6%. Es decir: los atributos de los jugadores dicen algo que las cuotas no estaban diciendo.

D10

Criterios de inclusión explícitos, nunca descartes silenciosos

Cuatro filtros sacan filas, y el log del task `armar_dataset` informa cuántas saca cada uno. El criterio común: si la fila no puede responder la pregunta, no entra.

Partidos en la base 25.979

Tras excluir 2 ligas sin ninguna cuota cargada 22.637 · -3.342

Polonia Ekstraklasa y Suiza Super League tienen 0% de cobertura de cuotas: ningún partido suyo puede definir favorito.

Con alineación titular completa (22 jugadores) 19.727 · -2.910

Sin alineación no hay features de jugadores, que son la mitad de la pregunta.

Con las 3 cuotas 1X2 de al menos una casa 19.694 · -33

Con una cuota faltante no se puede normalizar la tripleta ni definir favorito.

Con la tripleta coherente como mercado 19.662 · -32

Ver D11. Este cuarto criterio se incorporó al detectar cuotas corruptas en la fuente.

D11

Se exige que la tripleta sea un mercado coherente

Revisando el CSV aparecieron cuotas de empate imposibles: la mínima era 1,33, que implica un empate con 67% de probabilidad. Ningún mercado real de fútbol paga eso. El umbral no se eligió a ojo: se buscó dónde el dato deja de comportarse.

Calibración de la cuota de empate contra el resultado real

Probabilidad implícita cruda (1/cuota) contra la tasa de empate efectivamente observada.

1/ODDS_DRAW	PARTIDOS	EMPATES REALES	OVERROUND MEDIO
(0,00 - 0,20]	2.382	13,2%	1,0395
(0,20 - 0,25]	3.082	22,6%	1,0400
(0,25 - 0,28]	3.925	25,2%	1,0371

1/ODDS_DRAW	PARTIDOS	EMPATES REALES	OVERROUND MEDIO
(0,28 - 0,30]	4.777	27,4%	1,0400
(0,30 - 0,33]	4.857	30,0%	1,0502
(0,33 - 0,35]	614	30,0%	1,0628
(0,35 - 0,40]	25	28,0%	1,0645
(0,40 - 0,45]	9	44,4%	1,0786
(0,45 - 1,00]	23	56,5%	1,0903

Hasta 0,40 la cuota de empate está bien calibrada: la tasa real sube monótonicamente de 13,2% a 30,0% y el margen de la casa se queda cerca de 1,04. Pasando 0,40 las dos cosas se rompen al mismo tiempo — 44,4% y 56,5% de empates reales, con el margen saltando a ~1,09. El corte quedó en `MAX_PROB_EMPATE_IMPLICITA = 0.40`.

POR QUÉ SE EXCLUYEN Y NO SE MARCAN

Son 32 partidos (0,16%), todos entre 2008/09 y 2012/13 y casi todos de Serie A. En esas filas la tripleta no es un precio pre-partido, así que el favorito que se calcula a partir de ella no significa lo que el dataset dice que significa — y el target es "ganó el no favorito". Sin precio real no hay favorito real: la fila no puede responder la pregunta, igual que las de Polonia y Suiza.

Diccionario de columnas

Las 82 columnas, con su tipo, el porcentaje de nulos y el rango o los valores observados. Las columnas por lado se documentan una vez: `home_*` y `away_*` son idénticas en significado y se refieren al once local y al visitante respectivamente. Las filas resaltadas en ámbar son la clave primaria y el objetivo.

1 · Identidad del partido				
De dónde viene la fila. 11 columnas.				
COLUMNA	TIPO	NULOS	RANGO / VALORES	SIGNIFICADO
match_id PK	int	0%	483.130 - 2.216.672	Clave primaria: el match_api_id de la fuente. Es el test operativo de que una fila es un partido — si se duplicara, el pipeline estaría devolviendo el mismo partido dos veces.
liga	str	0%	9 valores	Nombre de la liga. Quedan 9 de las 11 de la base: se excluyen Polonia y Suiza por no tener cuotas.
pais	str	0%	9 valores	País de la liga. Uno por liga en este recorte.
temporada	str	0%	2008/2009 - 2015/2016	Temporada en formato AAAA/AAAA . 8 temporadas.
jornada	int	0%	1 - 38	Fecha del campeonato (stage en la fuente). El máximo varía según el tamaño de la liga.
fecha	date	0%	2008-08-09 - 2016-05-17	Fecha del partido. Es la referencia temporal contra la que se cortan los snapshots de atributos (D4).
equipo_local	str	0%	nombre largo	Nombre del equipo local, traído por team_api_id para que el CSV sea legible. El join nunca usa el nombre.
equipo_visitante	str	0%	nombre largo	Ídem para el visitante. Ojo: União de Leiria, SAD contiene una coma y va entrecomillado en el CSV (35 filas).
goles_local	int	0%	0 - 10	Goles del local al final del partido.
goles_visitante	int	0%	0 - 9	Goles del visitante al final del partido.
resultado_ft	str	0%	H · D · A	Resultado a tiempo completo: H ganó el local, D empate, A ganó el visitante. Derivado de los goles, no leído de la fuente.

2 · Mercado de apuestas				
Las cuotas pre-partido y su conversión a probabilidades. 8 columnas.				
COLUMNA	TIPO	NULOS	RANGO / VALORES	SIGNIFICADO
odds_source	str	0%	PS · B365 · BW · BS	Prefijo de la casa de apuestas cuya tripleta se usó en esta fila (D6). PS es Pinnacle, B365 Bet365.
odds_home	float	0%	1,04 - 36,00	Cuota decimal a que gane el local, tal como la publicó la casa.
odds_draw	float	0%	2,50 - 29,00	Cuota decimal al empate. El mínimo es 2,50 por el filtro de coherencia de mercado (D11); sin ese filtro bajaba a 1,33.
odds_away	float	0%	1,09 - 47,50	Cuota decimal a que gane el visitante.
overround	float	0%	1,0125 - 1,1260	Suma de las tres probabilidades crudas (1/cuota). El excedente sobre 1 es el margen que cobra la casa: media 1,0427, o sea 4,3%.
prob_home	float	0%	0,0272 - 0,9423	Probabilidad implícita normalizada de que gane el local: (1/odds_home) / overround .
prob_draw	float	0%	0,0338 - 0,3990	Probabilidad implícita normalizada de empate. El techo lo fija el filtro D11.

COLUMNA	TIPO	NULOS	RANGO / VALORES	SIGNIFICADO
prob_away	float	0%	0,0207 - 0,8988	Probabilidad implícita normalizada de que gane el visitante. Las tres <code>prob_*</code> suman 1,0 exactamente.

3 · Favorito y columna objetivo

Quién es el favorito según el mercado, y si el otro ganó. 7 columnas.

COLUMNA	TIPO	NULOS	RANGO / VALORES	SIGNIFICADO
prob_gap	float	0%	-0,8716 - 0,9184	<code>prob_home - prob_away</code> . Positivo significa que el favorito es el local. Nunca nula.
equipo_favorito	str	0,53%	local · visitante	Cuál de los dos tiene la probabilidad implícita más alta. El favorito es el local en el 72,2% de los partidos: la ventaja de localía. Nula cuando local y visitante tienen exactamente la misma probabilidad (105 partidos): no hay favorito definible.
prob_favorito	float	0,53%	0,2038 - 0,9423	Probabilidad implícita del favorito, o sea el máximo entre <code>prob_home</code> y <code>prob_away</code> . Mide cuán favorito es.
prob_no_favorito	float	0,53%	0,0207 - 0,3678	Probabilidad implícita del no favorito. El techo de 0,3678 no es un error: si los dos equipos estuvieran parejos, el empate se llevaría el resto.
es_partido_parejo	bool	0,53%	True 8,2%	True si <code> prob_gap < 0,05</code> , es decir cuando la etiqueta de favorito es prácticamente ruido. 1.607 partidos.
resultado_no_favorito	str	0,53%	gano · empate · perdio	Resultado del no favorito en tres niveles: <code>gano</code> 21,4%, <code>empate</code> 25,2%, <code>perdio</code> 53,4%. Es la columna que conserva la información que el target binario colapsa (D7).
gano_no_favorito OBJETIVO	bool	0,53%	True 21,4%	La columna objetivo. True si el no favorito ganó el partido. El empate es False (D7). Nula sólo cuando no hay favorito definible.

4 · Features del once titular · `home_*` y `away_*`

21 columnas por lado, 42 en total. Todas salen de los 11 jugadores que salieron a la cancha, con su snapshot de atributos anterior al partido. Los rangos mostrados son del lado local.

COLUMNA	TIPO	NULOS	RANGO / VALORES	SIGNIFICADO
home_best_overall away_best_overall	float	0%	62 - 94	Rating <code>overall</code> del mejor jugador del once. Un jugador concreto, no un promedio.
home_worst_overall away_worst_overall	float	0%	35 - 83	Rating del peor jugador del once: el eslabón más débil de la cadena.
home_top3_overall away_top3_overall	float	0%	61,67 - 92,33	Promedio de los 3 mejores individuos del once. Captura el núcleo de calidad sin diluirlo en los 11.
home_xi_overall_mean away_xi_overall_mean	float	0%	57,55 - 86,55	Promedio de <code>overall</code> de los 11 titulares. El nivel general del equipo que salió a jugar.
home_overall_std away_overall_std	float	0%	0,52 - 11,54	Desviación estándar del <code>overall</code> dentro del once. Alta = equipo estrella-dependiente; baja = parejo. Distingue dos equipos con el mismo promedio.
home_best_reactions away_best_reactions	float	0%	58 - 96	Mejor valor de <code>reactions</code> del once.
home_fastest_sprint_speed away_fastest_sprint_speed	float	0%	67 - 97	Velocidad punta del titular más rápido. Los arqueros no tienen <code>sprint_speed</code> cargado, así que sale de los jugadores de campo.

COLUMNA	TIPO	NULOS	RANGO / VALORES	SIGNIFICADO
home_strongest_strength away_strongest_strength	float	0%	68 - 96	Mayor valor de <code>strength</code> del once.
home_best_finishing away_best_finishing	float	0%	56 - 97	Mejor definidor del once, por el atributo <code>finishing</code> .
home_best_marking away_best_marking	float	0%	57 - 94	Mejor marcador del once, por el atributo <code>marking</code> .
home_xi_age_mean away_xi_age_mean	float	0%	20,42 - 33,08	Edad promedio del once a la fecha del partido, en años, calculada desde <code>birthday</code> .
home_xi_height_mean away_xi_height_mean	float	0%	174,1 - 189,8	Altura promedio del once en centímetros.
home_gk_overall away_gk_overall	float	0,02%	43 - 91	Rating del arquero titular concreto , identificado por su coordenada Y. Nula si ningún titular cae en la franja de arquero o si el arquero no tiene snapshot previo.
home_gk_reflexes away_gk_reflexes	float	0,02%	8 - 96	Reflejos del arquero titular. También sirve de desempate: en 3 de 39.388 alineaciones las coordenadas vienen en cero y dos titulares caen en la franja de arquero; se toma el de mejores reflejos, porque un arquero real tiene los <code>gk_*</code> muy por encima de un jugador de campo.
home_gk_diving away_gk_diving	float	0,02%	2 - 94	Atributo <code>gk_diving</code> del arquero titular.
home_gk_handling away_gk_handling	float	0,02%	9 - 92	Atributo <code>gk_handling</code> del arquero titular.
home_def_overall away_def_overall	float	0,01%	54,75 - 85,75	Promedio de <code>overall</code> de los titulares en la línea defensiva, según su coordenada Y (D8). Nula si la formación no tiene ningún titular en esa franja.
home_mid_overall away_mid_overall	float	0,01%	53,0 - 88,5	Ídem para el mediocampo. Leer junto a la limitación L1: los volantes por afuera con Y=8 no entran acá.
home_att_overall away_att_overall	float	0,02%	46,0 - 91,33	Ídem para el ataque. Incluye a los titulares con Y=8, que suelen ser de banda (L1).
home_formacion away_formacion	str	0%	4-4-2 · 4-3-3 · 4-2-4 ...	Cantidad de titulares por tercio de cancha, en formato <code>def-mid-att</code> . 12 valores distintos. No es la etiqueta táctica del entrenador : ver L1.
home_xi_sin_atributos away_xi_sin_atributos	int	0%	0 - 1	Cuántos de los 11 titulares no tenían ningún snapshot de atributos anterior al partido. Es el control de calidad de la propia fila: vale 0 en el 99,9% de los casos. Nunca nula.

5 · Diferencias local – visitante

10 columnas. Positivo significa que el local es superior en esa dimensión. Heredan nulo si falta cualquiera de los dos lados.

COLUMNA	TIPO	NULOS	RANGO / VALORES	SIGNIFICADO
xi_overall_mean_gap	float	0%	-17,27 - 18,91	Diferencia de nivel promedio entre los dos onces.
top3_overall_gap	float	0%	-19,00 - 19,67	Diferencia entre los núcleos de calidad (los 3 mejores de cada lado).
worst_overall_gap	float	0%	-32 - 32	Diferencia entre los eslabones más débiles de cada once.
gk_overall_gap	float	0,02%	-34 - 33	Diferencia entre los arqueros titulares.

COLUMNA	TIPO	NULOS	RANGO / VALORES	SIGNIFICADO
def_overall_gap	float	0,01%	-21,17 - 20,00	Diferencia entre las líneas defensivas.
mid_overall_gap	float	0,01%	-22,50 - 26,00	Diferencia entre los mediocampos.
att_overall_gap	float	0,02%	-27 - 32	Diferencia entre los ataques.
fastest_sprint_speed_gap	float	0%	-27 - 27	Diferencia entre los titulares más rápidos de cada lado.
best_finishing_gap	float	0%	-29 - 30	Diferencia entre los mejores definidores.
xi_age_mean_gap	float	0%	-7,36 - 8,31	Diferencia de edad promedio entre los dos onces, en años.

6 · Diferencias orientadas al no favorito

4 columnas. Positivo significa que el underdog es superior en esa dimensión — la forma directa de responder la pregunta (D9).

COLUMNA	TIPO	NULOS	RANGO / VALORES	SIGNIFICADO
nofav_xi_overall_mean_gap	float	0,53%	-18,91 - 10,09	Nivel promedio del once del no favorito menos el del favorito. Cuando es positivo, la tasa de triunfo del underdog sube de 19,3% a 28,6%.
nofav_top3_overall_gap	float	0,53%	-19,67 - 11,67	Ídem para los núcleos de calidad de cada equipo.
nofav_gk_overall_gap	float	0,55%	-34 - 30	Ídem para los arqueros titulares. Es la columna con más nulos del dataset: acumula la falta de arquero identificable y la falta de favorito.
nofav_fastest_sprint_speed_gap	float	0,53%	-27 - 22	Ídem para el titular más rápido de cada lado.

Nulos: documentados, o la corrida falla

El diccionario `NULL_REASONS` en `include/src/transform.py` registra, para cada columna que puede tener nulos, por qué los tiene. El chequeo de calidad **hace fallar la corrida** si aparece un nulo en una columna que no esté ahí. No es decorativo: fue exactamente lo que detectó una columna espuria (`home_nan` / `away_nan`) generada por un `unstack` sobre una categoría sin clasificar, que se colaba al CSV casi enteramente nula.

COLUMNAS	NULOS	MOTIVO
nofav_gk_overall_gap	0,55%	Falta el arquero identificable de alguno de los dos lados, o no hay favorito definible.
gano_no_favorito y las 5 derivadas del favorito	0,53%	Local y visitante con probabilidad implícita exactamente igual: no hay favorito definible. 105 partidos.
home_gk_* / away_gk_* home_att_overall / away_att_overall	0,02%	Sin slot de arquero identificable por coordenada Y, o titular sin snapshot de atributos anterior a esa fecha.
home_def_overall / away_def_overall home_mid_overall / away_mid_overall	0,01%	La formación de ese partido no tiene titulares clasificados en esa línea.

Los 7 criterios de calidad

Corren como último task del DAG, sobre el CSV final. Los seis marcados como duros hacen fallar la corrida; los números quedan en el log del task.

OK	clave_sin_duplicados — match_id es único en las 19.694 filas. DURO
OK	volumen_suficiente — más de 1.000 filas. DURO
OK	ancho_suficiente — al menos 5 columnas. DURO
OK	mezcla_de_tipos — al menos 2 tipos de dato distintos: hay int, float, str y bool. DURO
OK	nulos_conocidos — ninguna columna con nulos fuera de NULL_REASONS. DURO
OK	sin_columnas_vacias — ninguna columna enteramente nula. DURO
OK	clave_primaria_es_match_id — la clave declarada existe en el dataset.

Validación del contenido, no sólo del formato

Que el archivo tenga la forma correcta no dice nada sobre si la lógica del target está bien. La mejor evidencia de que no está invertida es que los números dan lo que el fútbol dice que tienen que dar.

Tasa de triunfo del no favorito según cuán favorito es el rival		
Si el target estuviera invertido, esta columna subiría en lugar de bajar.		
PROB_FAVORITO	PARTIDOS	GANÓ EL NO FAVORITO
hasta 0,40	3.364	31,8%
0,40 – 0,50	6.839	26,2%
0,50 – 0,60	4.207	19,2%
0,60 – 0,70	2.768	13,8%
0,70 – 0,80	1.745	7,2%
más de 0,80	666	2,9%

- El favorito es el local en el 72,2% de los partidos, lo que refleja la ventaja de localía.
- El no favorito gana el 21,4%, empata el 25,2% y pierde el 53,4%.
- La tasa de triunfo del underdog cae **monotónicamente** a medida que el favorito es más fuerte, de 31,8% a 2,9%.
- Los features de jugadores **aportan señal por encima de las cuotas**: con `nofav_xi_overall_mean_gap > 0` la tasa sube de 19,3% a 28,6%.

Limitaciones conocidas

L1

formacion es un binning de coordenadas, no una etiqueta táctica

Los cortes del código mandan `Y=8` a la línea de ataque, junto con los delanteros de `Y=10` y `Y=11` . Son 23.082 titulares. Un 4-4-2 real con dos volantes por afuera en `Y=8` sale etiquetado 4-

2-4, y de ahí que esa formación —que prácticamente no existe en el fútbol moderno— aparezca en 5.489 partidos, un 28% del dataset.

QUÉ IMPLICA AL USAR EL DATASET

`formacion` hay que leerlo como "cuántos titulares por tercio de cancha".

`att_overall` incluye jugadores de banda y `mid_overall` los excluye, así que las dos columnas están corridas respecto de la intuición táctica. Se arregla moviendo el corte de 7 a 8, pero eso redefine tres columnas y hay que rehacer la validación.

L2

La base termina en la temporada 2015/2016

Sirve para entrenar y validar, pero no para predecir un partido de la fecha que viene. Para eso haría falta enchufar una fuente de alineaciones y cuotas actuales, con el problema de que las alineaciones confirmadas se conocen recién ~1 hora antes del partido.

L3

No hay estado de forma

Los features son los atributos intrínsecos de los jugadores, no el rendimiento reciente del equipo. Se puede derivar desde los propios resultados de la base —puntos en los últimos 5 partidos— para la Entrega 2, cuidando de no introducir fuga temporal.

L4

Lesiones y suspensiones sólo de forma indirecta

No están como dato, pero se reflejan en la alineación: si un titular habitual no jugó, no aparece en el once de esa fila. Lo que no se captura es un jugador que juega lesionado.

L5

Errores puntuales de la fuente, ya medidos

De 39.388 alineaciones: 3 traen las coordenadas en cero (se resuelve eligiendo al arquero por sus reflejos), 4 no permiten clasificar alguna línea y quedan como nulos documentados, y 1 repite un jugador dentro del mismo once. En total menos del 0,02%. A esto se suman las 32 filas de cuotas incoherentes que D11 excluye.

Formato del archivo

- Ruta: `include/data/processed/underdog_dataset.csv`. No se versiona: lo regenera el DAG.
- Separador de campos coma, separador decimal **punto**, codificación UTF-8.
- Los flotantes se escriben con **4 decimales**. Las cuotas de origen vienen con 2, así que todo dígito más allá del cuarto es ruido de la división.

- 35 filas contienen el equipo `União de Leiria, SAD`, cuyo nombre lleva una coma. Va entrecomillado según el estándar CSV. Un visor que ignore el entrecomillado va a correr las columnas de esas filas.

Cómo se regenera

Proyecto Astro (Airflow). El DAG `underdog_pipeline` tiene tres tasks encadenados y está pensado para disparo manual, no para un schedule recurrente: `extraer_base` baja el SQLite de Kaggle (capa bronce, sin transformar), `armar_dataset` cruza partidos, cuotas y atributos por jugador y escribe el CSV (capa plata), y `chequear_calidad` corre los 7 criterios y falla la corrida si el dataset no pasa.

Documentación generada a partir del código en `include/src/transform.py`, `include/config.py` y `include/src/quality_check.py`, y de la medición directa sobre el CSV. Las cifras de filas, nulos y rangos corresponden a la última corrida verificada del pipeline (19.694 filas). El criterio D11 está implementado y baja el total a 19.662 filas al regenerarse.